


Rapport d'Audit de Performance — Poker Monte Carlo

Moteur Monte Carlo Texas Hold'em en Rust — **x147 de gain** sur la baseline naïve via 6 optimisations incrémentales (zero-alloc, eval7, LUT, Rayon).

<https://github.com/EAnathos/poker>

1. Présentation du projet



Ce projet implémente un **moteur de calcul de probabilités Monte Carlo** pour le Texas Hold'em en Rust. Étant donné un ensemble de mains et un board partiel, le moteur estime l'équité de chaque joueur par simulation répétée (50 000 à 500 000 itérations selon le scénario). Rust a été choisi dans une optique de découverte : le langage était nouveau, et ce projet, à la croisée des simulations haute fréquence, de la gestion mémoire fine et d'une interface graphique, correspondait aux thématiques du cours sur la performance système.

2. Environnement & Métrologie

2.1 Banques d'essai

Setup A (référence)

Composant	Détail
CPU	AMD Ryzen 5 5600H — 6C / 12T
Cache	L1 32 KiB/cœur · L2 512 KiB/cœur · L3 16 MiB partagé
RAM	16 GiB DDR4-3200
OS / Rust	Arch Linux kernel 7.1.11 · rustc 1.98.1

Des benchmarks complémentaires ont été réalisés sur Setup B (AMD Ryzen 7 7735U, Windows 11), documentant l'impact de NT Heap et du scheduler Windows. → [docs/benchmarks-setup-b.md](#)

2.2 Outils de mesure

Outil	Usage
Hyperfine	Mesure statistique de durée (100 runs, warmup 10)
Samplify	Flamegraph interactif → Firefox Profiler

Outil	Usage
perf	Compteurs matériels bas niveau (cache-misses, cycles)
just	Exécuteur de recettes — docs/commandes.md

Baseline Setup A — **naïve SC6 (500 000 itérations)** : moyenne 2,497 s, $\sigma = 14$ ms.

3. Scénarios de Benchmark

Six scénarios couvrent quatre axes : nombre de joueurs (2–4), stade de jeu (flop/turn), présence de joueur inconnu, connectivité du board. Le volume d'itérations est calibré pour 800 ms–1,8 s sur la baseline naïve (sauf SC6, dédié à la haute précision).

ID	Scénario	Joueurs	Board	Itérations	Erreur MC
SC1	AA vs KK vs QJs	3	Flop	50 000	$\pm 0,45$ %
SC2	AhKh vs 9c9d vs JcTc	3	Turn	75 000	$\pm 0,37$ %
SC3	7s6s vs AdKd vs QcQh	3	Flop	50 000	$\pm 0,45$ %
SC4	As5s vs KdKc vs QhJh vs ???	4	Flop	30 000	$\pm 0,58$ %
SC5	Ah5h vs JdJc vs 7c6c	3	Flop	50 000	$\pm 0,45$ %
SC6	AhKh vs QsQd (<i>haute précision</i>)	2	Flop	500 000	$\pm 0,14$ %

SC6 sert de référence de validation et d'amplificateur d'optimisation : son volume élevé rend visibles des gains noyés dans le bruit à 50 000 iters. → Descriptions détaillées des scénarios : [docs/details-optimisations.md](#)

4. Optimisations

4.1 ZeroAllocEvaluator — Élimination des allocations heap

Diagnostic. **naïve** effectue ≈ 11 M allocations heap par run SC6 (87 % dans `evaluate_five`, appelée 21×/itération via les C(7,5) combos).

Hypothèse. Remplacer `Vec + HandValue { tiebreak: Vec<u8> }` par des tableaux stack et un `u32` encodé (bits 23:20 = catégorie, bits 19:0 = tiebreaks) supprime la pression allocateur → gain $\times 2$ –3.

Résultat SC6. 196 900 → 461 700 iters/s — **$\times 2,31$** . σ réduit de 17 ms à 11 ms (élimination des pics de latence allocateur).

Analyse. Confirmé. Le profil révèle que les deux `sort_unstable_by` internes représentent ~ 30 % du runtime. La section suivante montre que ce coût est mal interprétable : sur $n = 5$ éléments en L1, l'insertion sort est quasi-gratuit. → Profil samplé complet : [docs/details-optimisations.md](#)

4.2 SortFreeEvaluator — Suppression des tris (invalidée)

Hypothèse. Remplacer les deux `sort_unstable_by` d'`eval5` par un scan freq-table (quinte) et des buckets typés (groupes) → Amdahl théorique $\times 1,43$.

Résultat SC6. 461 700 → 399 000 iters/s — **régression $\times 0,86$** .

Analyse. L'insertion sort sur 5 octets (L1, ~ 12 comparaisons inlinées par LLVM) est plus rapide que le remplacement proposé, qui ajoute ~ 17 opérations. Enseignement clé : le flamégraph montre où le temps est dépensé, pas pourquoi. `eval5` concentrait 50 % du runtime parce qu'elle était appelée 21× par itération — le vrai levier n'était pas son implémentation mais sa fréquence d'appel.

4.3 FisherEvaluator — Partial Fisher-Yates + Lemire

Hypothèse. Remplacer le shuffle complet $O(|deck|)$ par partial Fisher-Yates $O(n_{\text{needed}})$ + Lemire range reduction (multiplication 128-bit au lieu de division entière) → Amdahl $\times 1,05$.

Résultat SC6. 461 700 → 508 800 iters/s — **×1,10**. Gain légèrement supérieur car la suppression de ~1 M de divisions entières à 500k iters est significative en absolu.

Analyse. Confirmé. Le shuffle ne dépasse pas ~5 % du runtime : ce levier est plafonné. → Résultats SC1–SC5 : [docs/details-optimisations.md](#)

4.4 Eval7Evaluator — Évaluation directe 7 cartes

Diagnostic. **best7** appelle **eval5** 21× par joueur par itération (C(7,5) combos). Sur SC6 (500k iters, 2 joueurs) : ≈ 2,52 milliards d'instructions pour **best7** seul.

Hypothèse. Une passe directe sur 7 cartes (freq-table + suit-table → catégorie sans énumération) réduit le nombre d'évaluations de 21 à 1 → gain ×10–15.

Résultat SC6. 508 800 → 7 042 300 iters/s — **×13,84 vs fisher, ×35,8 vs naive**.

Analyse. Gain dominant de la chaîne. Réduction i-cache (1 appel vs 21) et branch predictor (patterns stables vs 21 sous-ensembles différents) expliquent le ×14. Les micro-optimisations 4.1–4.3 (×2,6 cumulé) deviennent marginales. → Résultats SC1–SC5 : [docs/details-optimisations.md](#)

4.5 LutEvaluator — Tables pré-calculées + seuil adaptatif

Hypothèse. Précalculer toutes les valeurs de mains dans deux tables indexées (flush 32 Ko → L1 ; non-flush 1,5 Mo → L3 après warmup) réduit l'évaluation à ~25 instr. + 1–2 accès cache → gain ×1,5–2 à ≥ 200 000 itérations.

Implémentation. Seuil unique résolu avant la boucle (**lut_opt**: `Option<&'static LutData>`), LLVM hisse la branche hors du hot path. En dessous du seuil, **eval7_inline** s'exécute sans initialisation des tables.

Résultat SC6. 7 042 300 → 11 520 700 iters/s — **×1,64**. SC1–SC5 (< 200k iters) : ~×1,0. RAM : +1,6 Mo sur SC6, 0 Mo supplémentaire sur SC1–SC5.

Analyse. Gain inférieur à la prédiction : la chaîne de 13 multiply-add dans **freq_key** (dépendance séquentielle → ~39 cycles de latence) compense une partie du gain sur l'accès L3.

4.6 LutParEvaluator — Parallélisation via Rayon

Hypothèse. La simulation Monte Carlo est embarrassingly parallel (itérations indépendantes). Distribution sur N threads Rayon avec RNG par thread (seeding Fibonacci doré) → speedup ×4–6 sur 6 cœurs physiques.

Résultat SC6. 11 520 700 → 28 902 000 iters/s — **×2,47** (SC1–SC4 : ×3,1–3,5).

Analyse. SC6 limité par : (1) build LUT sériel (Amdahl, fraction non-parallélisable ~6 %) et (2) contention bande passante L3 (1,5 Mo partagé entre 6 threads → 3,6 threads effectifs vs 5,6 pour SC4 sans LUT). → Analyse User time par scénario : [docs/details-optimisations.md](#)


4.7 Bilan — Synthèse des optimisations

Évaluateur	Iters/s	Speedup vs naive	Peak RSS	Type
naive	196 900	×1,0	2,6 Mo	référence
zero_alloc	489 100	×2,5	2,6 Mo	micro
sort_free	399 000	×2,0	2,6 Mo	micro (régression SC6)
fisher	508 800	×2,6	2,6 Mo	micro
eval7	7 042 300	×35,8	2,6 Mo	macro
lut	11 520 700	×58,5	4,2 Mo	macro
lut_par	28 902 000	×146,8	4,4 Mo	macro


Le gain total **×147** se décompose : $\times 2,6$ (micro) $\times \times 13,7$ (eval7/fisher) $\times \times 1,6$ (lut) $\times \times 2,5$ (lut_par) $\approx \times 147$.

RAM : naive–eval7 restent à ~2,6 Mo. **lut** ajoute +1,6 Mo (flush 32 Ko + non-flush ~1,5 Mo). **lut_par** ajoute +0,2 Mo (stacks threads Rayon). Sur SC1–SC5 (< 200k iters), **lut** affiche ~2,6 Mo : tables non allouées.

Progression iters/s SC6



lut vs lut_par — iters/s par scénario



5. Annexes

Document	Contenu
docs/details-optimisations.md	Descriptions SC1–SC6, profils samplly, résultats SC1–SC5 par évaluateur, implémentations complètes
docs/benchmarks-setup-b.md	Benchmarks Setup B (Windows) — données brutes et analyses §4.1 à §4.6
docs/mise-en-place.md	Installation des outils et activation des symboles debug

Document	Contenu
docs/commandes.md	Référence complète des commandes just
docs/gouvernance-ia.md	Constitution technique IA — directives CLAUDE.md